

Ex. 1 On note, pour tout $x \in \mathbb{R}$, $\sigma(x) = \frac{1}{1+e^{-x}}$.

Vérifier que :

$$\sigma' = (1 - \sigma)\sigma,$$

$$(\ln(\sigma(u)))' = (1 - \sigma)u',$$

$$(\ln(1 - \sigma(u)))' = -\sigma(u)u'.$$

Rappel :

$$(u(v))' = u'(v) \times v' \text{ avec comme cas particuliers : } (\ln(u))' = \frac{u'}{u}, (e^u)' = u'e^u.$$

Rappel de cours : **Maximum de vraisemblance.**

Étant données des observations $X_j \mapsto Y_j$, $j \in \{1, \dots, J\}$, avec $X_j \in \mathbb{R}^n$ et $Y_j \in \{0, 1\}$, on cherche à expliquer les valeurs de Y à partir de celle de X .

À cette fin, on suppose que les valeurs Y_j sont issues d'une loi de probabilité conditionnelle $P : X \mapsto \Pr(Y = 1|X)$, associant à chaque X la probabilité que $Y = 1$.

L'analyse de données vise à déterminer P .

Si les valeurs de Y sont effectivement issues de P , alors étant donné X_j , la probabilité d'observer $Y = 1$ est $P(Y = 1|X_j)$, et celle d'observer $Y = 0$ est $1 - P(Y = 1|X_j)$. Plus généralement, si chaque observation est indépendante des autres, alors la *vraisemblance* de la loi P , donnée par

$$L(P) = \prod_{j:Y_j=1} P(Y = 1|X_j)^{Y_j} \prod_{j:Y_j=0} (1 - P(Y = 1|X_j))$$

est la probabilité d'observer $Y = Y_1$ étant donné X_1 et $Y = Y_2$ étant donné X_2 et ... et $Y = Y_J$ étant donné X_J . C'est la probabilité d'observer les données effectivement observées.

En général, on paramétrise P , et le problème est alors de trouver la valeur des paramètres maximisant la vraisemblance de P .

Ex. 2 On considère les observations :

$$X_1 = \begin{pmatrix} 1 & 1 \end{pmatrix} \mapsto Y_1 = 1, X_2 = \begin{pmatrix} 1 & 0 \end{pmatrix} \mapsto Y_2 = 0, X_3 = \begin{pmatrix} 0 & 1 \end{pmatrix} \mapsto Y_3 = 0 \text{ et } X_4 = \begin{pmatrix} 0 & 0 \end{pmatrix} \mapsto Y_4 = 0.$$

On considère la famille de lois de probabilité paramétrée par b, w_1, w_2 , définies pour tout $X = \begin{pmatrix} x_1 & x_2 \end{pmatrix}$, par

$$P(Y = 1|X) = \sigma(b + w_1x_1 + w_2x_2)$$

avec $b, w_1, w_2 \in \mathbb{R}$.

1. Expliciter la log-vraisemblance, donnée par

$$\begin{aligned} \ln(L(b, w_1, w_2)) \\ = \sum_{j: Y_j=1} (\ln(P(Y = 1|X_j))) + \sum_{j: Y_j=0} (\ln(1 - P(Y = 1|X_j))). \end{aligned}$$

pour la loi $P : X \mapsto \sigma(b + w_1x_1 + w_2x_2)$ et pour les données (Y_j, X_j) ci-dessus.

2. Vérifier que $(b, w_1, w_2) \mapsto \ln(L(b, w_1, w_2))$ est une fonction partout concave.
Indication : La somme de fonctions concaves est concave : il suffit donc de montrer que chaque terme de la vraisemblance est une fonction concave. Par ailleurs, il est possible d'utiliser le critère de Sylvester pour montrer qu'une fonction est concave : une fonction est concave si la fonction opposée est convexe.
3. Puisque $\ln(L(b, w_1, w_2))$ est partout concave, si elle atteint un maximum alors en ce maximum, $[\text{grad } \ln(L)](b, w_1, w_2) = 0$.
Expliciter le système d'équations $[\text{grad } \ln(L)](b, w_1, w_2) = 0$. Ce système possède-t-il une solution ?